Dawid-Skene 기반 MAP 추론을 이용한 다중클래스 라벨 추정 성능 비교*

최현준O, 서한빛, 오홍석, 이의종†
충북대학교 소프트웨어학부
{chyunjoon06, hb.seo-isw, hs.oh-isw, kongjjagae†}@cbnu.ac.kr

Performance Comparison of Dawid-Skene-Based MAP Inference for Multi-Class Label Estimation

Hyunjoon ChoiO, Hanbit Seo, Hongseok Oh, Euijong Lee†
School of Computer Science, Chungbuk National University
{chyunjoon06, hb.seo-isw, hs.oh-isw, kongjjagae†}@cbnu.ac.kr

요 약

전문 지식이 요구되는 분야에 기계학습을 적용할 때, 초기 학습 데이터의 부족이나 클래스 간 높은 유사성은 충분한 분류 정확도를 확보하는 데 어려움으로 작용한다. 이에 비용 효율적인 대안으로 비전문 라벨러를 활용하는 방식이 주목받고 있으나, 응답의 오류와 불일치를 보정할 신뢰할 수 있는 집계 방법이 요구된다. 본 연구는 이러한 제약 하에서 Dawid-Skene(DS) 기반 Maximum A Posteriori(MAP) 추론을 비전문 라벨러의 응답 집계에 적용하고, 시뮬레이션을 통해 실제 라벨(ground truth) 추정 성능을 평가하였다. 오류의 구조적 집중도, 클래스 불균형, 라벨러 풀의 이질성 등을 변인으로 설정하여 단순 다수결(Majority Voting)과 비교 분석한 결과, MAP 추론은 대부분의 조건에서 우수한 성능을 보였으며, 특히 오류가 특정 클래스 쌍에 집중되거나 전문가가 포함된 환경에서 그 이점이 극대화되었다. 또한, 클래스 불균형 상황에서도 안정적인 성능을 유지하며, 라벨러의 평균 정확도가 일정 수준 이상일 경우 소수의 인원만으로도 목표 정확도(90%)를 달성할 수 있음을 확인하였다. 본 결과는 DS 기반 MAP 추론이 자동 채점 보조 및 라벨 데이터 확장 도구로 활용될 수 있는 근거를 제시한다.

1. 서 론

최근 기계학습 기반 자동화가 다양한 분야로 확대되고 있으나, 생물정보학적 이미지 분류처럼 전문 지식이 요구되는 분야에서는 학습 데이터 부족과 클래스 간 높은 유사성으로 인해 충분한 분류 정확도를 확보하기 어렵다[1]. 특히 교육 현장에서 학생 응답 처리 자동화를 위한 기계학습 모델 학습에는 대규모 정답 데이터가 필요하지만, 전문적 라벨링에는 상당한 비용이 소요된다. 이러한 제약 속에서 비전문가의 분류 응답을 신뢰성 있게 집계하여 기계학습 라벨로 활용하는 접근이 주목받고 있다[2].

응답 집계 방식으로는 기존 분류 모델의 예측치를 활용하거나 단순 다수결(Majority Voting)을 적용할 수 있다[3]. 그러나 학습 데이터가 부족한 초기 단계에서는 모델 예측의 신뢰도가 낮고, 오답이 포함된 예측치를 재학습에 사용할 경우 오류가 누적될 수 있다. 또한 혈액 세포 분류와 같이 형태적으로 유사한 클래스 쌍에서 구조적 혼동이 발생하거나 클래스 불균형이 존재하는 경우, 단순 다수결은 라벨러 평균 정확도가 낮을수록 안정적인 결과를 보장하기 어렵다.

본 연구에서는 이러한 조건에서 Dawid-Skene(DS) 기반 MAP 추론이 단순 다수결 대비 가지는 성능 이점을 시뮬레이션을 통해 분석한다[4]. 구체적으로 오류의 구조적 집중도, 클래스 불균형 수준, 라벨러 풀의 이질성 및 전문가 포함 여부가 집계 성능에 미치는 영향, 목표 정확도 달성을 위한 라벨러 규모를 정량적으로 평가하여, DS 모델의 자동 채점 보조 및 라벨 데이터 확장 도구로서의 활용 가능성을 검토한다.

2. 연구 방법

본 연구는 6개 혈액 세포 클래스를 구분하는 다중 클래스 분류 태스크를 가정한다. 각 라벨러 i의 응답 특성은 혼동행렬 $C_i \in \mathbb{R}^{K\times K}$로 표현하며, $C_i[m,a]$는 실제 클래스가 m일 때 라벨러 i가 a라고 응답할 확률을 의미한다[4]. 각 행은 확률분포이므로 $\sum_{a=1}^{K} C_i[m,a] = 1$이다.

실제 클래스 y가 주어졌을 때 각 라벨러의 응답은 서로 조건부 독립이라고 가정한다[4]. N명의 라벨러 응답 $a_1,\ldots,a_N$가 주어졌을 때, MAP 추정은 식(1)과 같다[4].

$$\hat{y}_{MAP} = \arg\max_m [\log P(m) + \sum_{i=1}^{N} \log C_i[m,a_i]] \quad (1)$$

여기서 $P(m)$은 클래스 m의 사전확률이며, 클래스 불균형이 집계 성능에 미치는 영향을 분석하기 위해, 각 클래스의 비율을 연구자가 임의로 설정한 불균형 분포를 사용하였다. 비교 기준으로는 라벨러별 신뢰도를 구분하지 않는 단순 다수결(majority voting)을 함께 평가하였다.

* 이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 지역지능화혁신인재양성사업임 (IITP-2026-RS-2020-II201462)

† : 교신저자

2.1 시뮬레이션 설계

실제 비전문가(학생) 응답 데이터 수집 전 DS 기반 집계의 적용 가능성을 검토하기 위해 시뮬레이션을 수행하였다. 기본 설정은 클래스 수 6개, 샘플 수 5,000개, 라벨러 수 20명이며, 결과는 10개 시드에 대한 평균과 표준편차(mean ± std)로 보고하였다.

시뮬레이션은 가정된 클래스 사전분포로부터 실제 라벨(ground truth)을 샘플링한 뒤, 라벨러별 혼동행렬에 따라 개별 응답을 생성하는 방식으로 진행하였다. 혼동행렬의 대각 성분(정답률)은 실험 조건으로 설정된 목표 정확도에 맞추고, 나머지 오답 확률 질량은 디리클레(dirichlet) 분포를 통해 비대각 성분에 배분하였다[5]. 구조적 혼동 조건에서는 오류 질량이 Band-Seg (class 0-1), Band-Monocyte (class 0-3)와 같은 특정 클래스쌍에 집중되도록 설정하였다. 클래스 불균형, 라벨러 풀의 이질성, 전문가 포함 여부는 각 실험 목적에 따라 조작하거나 고정하였다. 또한 본 연구는 추정 오차의 개입을 배제한 알고리즘 자체의 유효성을 평가하기 위해, 생성된 혼동행렬 정보를 직접 활용하는 oracle setting을 전제한다.

3. 실험 및 분석

3.1 구조적 혼동 집중도에 따른 집계 성능 비교

오류의 구조적 집중도가 증가함에 따라 DS 기반 MAP 추론과 단순 다수결의 집계 성능이 어떻게 달라지는지 분석하였다. 이를 위해 개별 라벨러의 평균 정확도를 고정한 상태에서 비대각(off-diagonal) 성분의 오류 질량 집중도(focus ratio)를 0.0에서 1.0까지 변화시켰다. 여기서 focus ratio 0.0은 오류가 모든 오답 클래스에 균등하게 분산된 상태를, 1.0은 오류가 특정 혼동 쌍(예: class 0-1, 0-3)에 완전히 집중된 상태를 의미한다.

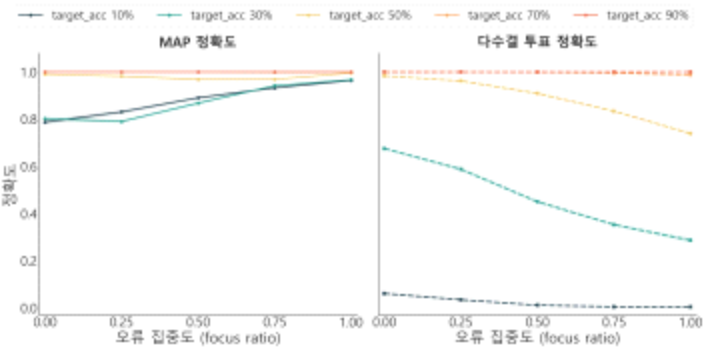


그림 1. 오류 집중도에 따른 MAP 추론과 다수결 투표의 정확도

표 1. 평균 정확도와 오류 집중도에 따른 MAP-다수결 정확도 격차(%p)

정확도	오류 집중도				
	0.00	0.25	0.50	0.75	1.00
10%	72.6±1.0	79.6±0.6	87.9±0.5	92.8±0.5	95.9±0.2
30%	12.7±0.7	20.3±0.7	41.8±1.0	58.9±0.5	68.0±0.9
50%	0.7±0.1	2.0±0.3	5.9±0.4	13.5±0.3	25.7±0.5
70%	0.0±0.0	0.0±0.0	0.1±0.1	0.4±0.1	1.2±0.1
90%	0.0±0.0	0.0±0.0	0.0±0.0	0.0±0.0	0.0±0.0

그림 1의 분석 결과, 다수결 투표는 라벨러 평균 정확도가 낮은 조건일수록 오류 집중도가 증가함에 따라 정확도가 감소하는 반면, MAP 추론은 대부분의 평균 정확도 조건에서 오류 집중도가 증가하더라도 높은 정확도를 유지하거나 점진적으로 향상되는 경향을 보였다. 특히 표 1에 따르면, 평균 정확도 30% 조건에서 MAP과 다수결의 정확도 격차는 focus ratio 0.0일 때 12.7%p였으나, focus ratio 1.0에서는 68.0%p까지 증가하였다. 평균 정확도 70% 이상에서는 다수결만으로도 높은 정확도에 도달하여 두 방식 간 차이가 작게 나타났다. 이러한 결과는 구조적 혼동이 강한 환경에서, 라벨러의 평균 정확도가 낮을수록 DS 기반 MAP 추론이 단순 다수결보다 비교적 안정적인 집계 성능을 제공할 수 있음을 보여준다.

3.2 클래스 불균형 수준에 따른 집계 성능 분석

클래스 불균형이 집계 성능에 미치는 영향을 분석하기 위해, 클래스를 균등 분포, 약한 불균형[0.35, 0.25, 0.15, 0.10, 0.10, 0.05], 강한 불균형 [0.70, 0.15, 0.06, 0.04, 0.03, 0.02]의 세 수준으로 설정하여 MAP 기반 DS 추론과 다수결 성능을 비교하였다. 각 결과값은 라벨러 평균 정확도 5개 수준(10%, 30%, 50%, 70%, 90%)에서 측정된 정확도의 산술 평균이며, 그림 2에 이를 제시하였다.

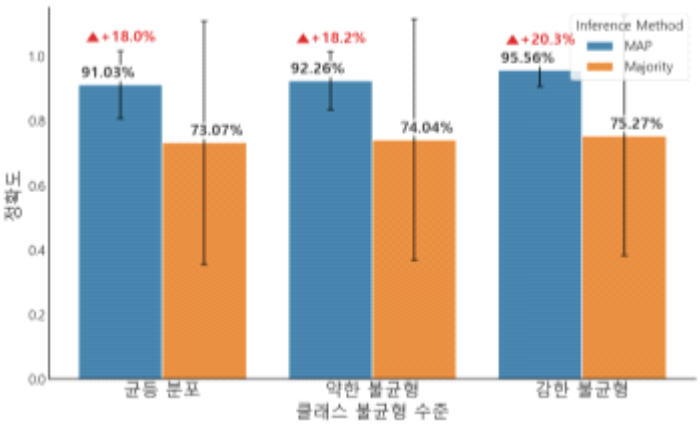


그림 2. 클래스 불균형 수준별 MAP와 다수결 정확도 비교

분석 결과, 모든 불균형 조건에서 MAP 기반 추론이 단순 다수결보다 일관되게 높은 정확도를 기록하였으며, 강한 불균형 조건에서도 이러한 우위는 유지되었다. 이는 MAP 추론이 라벨러별 혼동 특성과 클래스 사전확률(prior)을 함께 반영함으로써 불균형 환경에서도 비교적 안정적인 추론을 수행할 수 있음을 입증한다.

또한, 다수결은 라벨러의 품질에 따라 성능 편차(error bar)가 크게 나타나는 반면, MAP은 상대적으로 좁은 오차 범위를 유지하였다. 이는 다양한 라벨러 품질과 클래스 불균형이 혼재된 실제 환경에서 DS 기반 MAP 추론이 다수결보다 안정적인 집계 기준으로 활용될 가능성을 보여준다.

3.3 라벨러 풀 이질성과 전문가 포함 효과

집단 평균 정확도를 30%로 통제한 상태에서, 라벨러 풀의 구성(이질성)과 전문가의 포함 여부가 집계 성능에 미치는 영향을 비교 분석하였다. 동질 풀은 정확도 30%의 라벨러 20명으로 구성하였으며, 이질 풀은 동일한 인원과 평균 정확도를 유지하되 전문가·중급자·초보자를 혼합하여 구성하였다. 전문가의 정확도는 각각 50%와 90%인 두 가지 시나리오를 상정하였다.

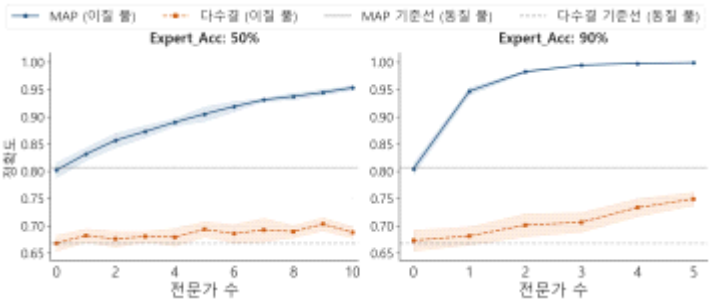


그림 3. 전문가 포함에 따른 동질 풀과 이질 풀의 정확도 비교

그림 3의 분석 결과, 동질 풀(기준선) 대비, 전문가가 포함된 이질 풀에서 MAP 추론의 성능 향상이 두드러졌다. 특히 전문가의 정확도 90% 시나리오(우측 그래프)에서는 1~2명의 전문가만 포함되어도 MAP 정확도가 95% 수준까지 상승하였다. 반면 다수결은 전문가 수가 증가하더라도 성능 향상 폭이 매우 제한적이었는데, 이는 전문가의 정답이 다수 초보자의 오답에 의해 상쇄되기 때문으로 해석된다.

이러한 결과는 DS 기반 MAP 추론이 개별 라벨러의 신뢰도를 차등적으로 반영하여, 교수자·조교·학생 응답이 혼재된 실제 교육 현장에서 소수의 고숙련자의 정보를 효과적으로 활용해 전체 채점 신뢰도를 향상시킬 수 있는 실용적 가능성을 제시한다.

3.4 목표 정확도 달성에 필요한 최소 라벨러 수 분석

본 절에서는 MAP 추론이 전체 집계 정확도 90%를 달성하기 위해 요구되는 최소 라벨러 수 N을 분석하였다. 실험은 집단 평균 정확도(10%–90%)와 오류 집중도(0.00–1.00)의 2차원 격자 환경에서 수행되었으며, 클래스 분포는 앞선 실험과 동일한 약한 불균형 분포를, 라벨러 풀 구성 효과를 배제하기 위해 동질 풀을 가정하였다.

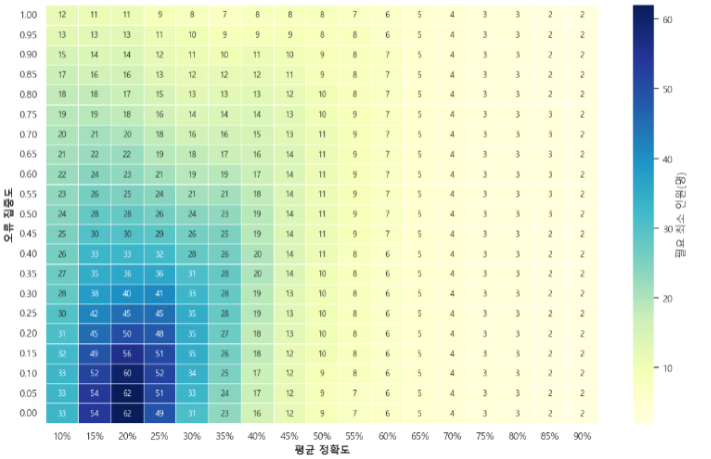


그림 4. 평균 정확도와 오류 집중도에 따른 목표 정확도 90% 달성 최소 라벨러 수

분석 결과(그림 4), 필요 인원이 가장 높은 영역은 평균 정확도 15–20% 및 오류 집중도가 낮아지는 구간으로 나타났다. 이 구간은 6-클래스 분류의 무작위 선택 기준선(≈16.7%)에 근접하여 개별 라벨러 응답의 정보량이 제한적이므로 목표 정확도 달성에 많은 인원이 요구된다. 반면 평균 정확도 70% 이상의 고품질 집단에서는 오류 집중도와 무관하게 5명 이하로 목표를 달성할 수 있었다. 또한 평균 정확도가 낮더라도 오류 집중도가 높은 경우에는 필요 인원이 상대적으로 감소하였는데, 이는 일관된 구조적 오답 패턴이 MAP 추론에서 유의미한 신호로 활용될 수 있음을 시사한다.

4. 결론 및 향후 연구

본 연구는 전문 지식이 요구되는 생물정보학 교육 환경에서 비전문가의 다중 클래스 분류 응답을 집계하기 위한 Dawid-Skene 기반 MAP 추론의 적용 가능성을 시뮬레이션으로 분석하였다. 실험 결과, MAP 추론은 구조적 혼동, 클래스 불균형, 전문가가 포함된 이질적 라벨러 풀에서 단순 다수결보다 안정적인 성능을 보였다. 특히 일관된 오답 패턴을 라벨러별 혼동 특성으로 반영함으로써 다수결 대비 높은 정확도를 보였으며, 라벨러 평균 정확도와 오류 집중도에 따라 목표 정확도 달성에 필요한 최소 라벨러 수가 달라짐을 확인하였다. 본 실험은 실제 교육 환경에서 발생할 수 있는 다양한 라벨링 상황을 모의적으로 반영한 것으로, DS 기반 MAP 추론의 적용 가능성과 라벨러 규모 설계를 검토하기 위한 기초 자료를 제시한다. 또한 전문가 전수 라벨링의 부담을 완화하고, 신뢰도 높은 정답 자원을 기계학습 모델의 학습 데이터로 활용할 수 있는 가능성을 시사한다.

다만 본 연구는 실제 학생 응답 데이터가 아닌 시뮬레이션 기반 분석이며, 라벨러의 혼동행렬을 사전에 알고 있는 oracle setting과 조건부 독립성 가정을 전제하였다는 한계가 있다. 향후 연구에서는 실제 학생 응답 데이터를 수집하고, Expectation-Maximization(EM) 알고리즘 기반 혼동행렬 추정 과정에서 발생할 수 있는 초기화 민감성, 표본 부족, 추정 오차를 검토하는 한편[4],[6], 클래스별 재현율, 소수 클래스 성능, 라벨러 수 대비 비용 효율성을 분석하여 본 시뮬레이션 결과와의 정합성을 실증적으로 확인하고자 한다.

참고 문헌

[1] Jeong, Kyungchang, et al. "A two-stage ai framework to detect and classify white blood cells for supporting diseases diagnosis in veterinary medicine." 2024 IEEE International Conference on Bioinformatics and Biomedicine (BIBM). IEEE, 2024.

[2] Raykar, Vikas C., et al. "Learning from crowds." Journal of machine learning research 11.4 (2010).

[3] Sheng, Victor S., Foster Provost, and Panagiotis G. Ipeirotis. "Get another label? improving data quality and data mining using multiple, noisy labelers." Proceedings of the 14th ACM SIGKDD international conference on Knowledge discovery and data mining. 2008.

[4] Dawid, Alexander Philip, and Allan M. Skene. "Maximum likelihood estimation of observer error-rates using the EM algorithm." Journal of the Royal Statistical Society: Series C (Applied Statistics) 28.1 (1979).

[5] Liu, Qiang, Jian Peng, and Alexander T. Ihler. "Variational inference for crowdsourcing." Advances in neural information processing systems 25 (2012).

[6] Dempster, Arthur P., Nan M. Laird, and Donald B. Rubin. "Maximum likelihood from incomplete data via the EM algorithm." Journal of the royal statistical society: series B (methodological) 39.1 (1977).